

A decorative border surrounds the central text. At the top left, there's a blue blood pressure cuff and a red stethoscope. Next to it is a blue pill bottle. At the top right, a blue glucometer is visible. The bottom left features a blue blood pressure cuff, a black stethoscope, and several red blood cells. The bottom right shows a blue glucometer, a white pill bottle, and a blue smartphone.

PREVEDERE IL DIABETE CON IL MACHINE LEARNING

Di Filippo La Greca

A decorative border surrounds the central text, featuring various medical and scientific icons. At the top left, there is a blue stethoscope, a blue pill bottle, and a red pill. At the top right, a blue medical device with a dial is visible. At the bottom left, a blue blood pressure cuff, a black reflex hammer, and several red blood cells are depicted. At the bottom right, a blue and white digital scale, a white pill bottle, and a blue container with white pills are shown.

LINK PROGETTO

<https://drive.google.com/file/d/1xIG0ipxk1thN24jN7QEMZHSXAeDbau6N/view?usp=sharing>

Introduzione progetto

- Il diabete è una malattia cronica molto diffusa che necessita monitoraggio continuo
- Le organizzazioni sanitarie puntano spesso su analisi dei dati per monitorare e/o prevenire la malattia
- Il Machine Learning (ML) rappresenta uno dei migliori strumenti per l'analisi dati e per formulare previsioni future

OBIETTIVO PROGETTO

Costruire miglior modello ML per
predire progressione malattia diabete a 1 anno



Metodologia

- Dati clinici di pazienti diabetici (dataset Diabetes di scikit-learn)
- Analisi esplorativa dei dati (EDA)
- Applicazione modelli di Machine Learning (ML supervisionato)
- Confronto delle performance dei modelli

FLOW DEL PROGETTO

Dataset → EDA → ML training/testing → Risultati → Conclusioni




EDA: insight generali

- Dataset composto da 10 variabili numeriche continue con info cliniche (X): caratteristiche generali + indicatori metabolici (Fig.1)
- Presenza di una variabile numerica continua target (y): progressione del diabete a 1 anno (Fig.1)
- Nessun valore mancante (Fig.1)
- Variabili già standardizzate/normalizzate (Fig.2)

OSSERVAZIONI

Dato che il dataset è già pulito e standardizzato, possiamo concentrarci direttamente sulle relazioni tra le variabili



EDA: insight generali

Data columns (total 11 columns):				
#	Column	Non-Null Count	Dtype	
0	age	442 non-null	float64	
1	sex	442 non-null	float64	
2	bmi	442 non-null	float64	
3	bp	442 non-null	float64	
4	s1	442 non-null	float64	
5	s2	442 non-null	float64	
6	s3	442 non-null	float64	
7	s4	442 non-null	float64	
8	s5	442 non-null	float64	
9	s6	442 non-null	float64	
10	target	442 non-null	float64	

Nessun valore mancante

Variabile numerica continua

Fig.1 Dataset completo (feature + target)

age	sex	bmi	bp	s1	s2	s3	s4	s5	s6	target
0.038076	0.050680	0.061696	0.021872	-0.044223	-0.034821	-0.043401	-0.002592	0.019907	-0.017646	151.0
-0.001882	-0.044642	-0.051474	-0.026328	-0.008449	-0.019163	0.074412	-0.039493	-0.068332	-0.092204	75.0
0.085299	0.050680	0.044451	-0.005670	-0.045599	-0.034194	-0.032356	-0.002592	0.002861	-0.025930	141.0
-0.089063	-0.044642	-0.011595	-0.036656	0.012191	0.024991	-0.036038	0.034309	0.022688	-0.009362	206.0
0.005383	-0.044642	-0.036385	0.021872	0.003935	0.015596	0.008142	-0.002592	-0.031988	-0.046641	135.0

Target non normalizzato


Fig.2 Dataset standardizzato/normalizzato

EDA: insight principali

- Analizzata la correlazione tra feature e target
- Feature più correlate con la progressione: bmi (~ 0.59), s5 (~ 0.57), bp (~ 0.44), s4 (~ 0.43) (Fig.1,3)
- Alcune feature mostrano correlazione negativa es. s3 (~ -0.39) (Fig.1,3)
- Distribuzione del target: continua e abbastanza dispersa, nessuna forte asimmetria o outlier estremi (Fig.2)

INSIGHT

- 1) Relazioni significative $\rightarrow$ utili per la modellazione
- 2) Possibile struttura prevalentemente lineare



EDA: insight principali

Leggera asimmetria dx (mean > median) ma non estrema




Fig.1 Correlazione feature-target






Fig.2 Distribuzione target




EDA: insight principali

COLR
PDS

↑ BMI*
↑ S5*
↑ BP*
↑ S4*
↑ TARGET/
DIABETES

*BMI (massa corporea), S5 (trigliceridi), BP (pressione), S4 (equilibrio lipidico) crescono, TARGET cresce
→ diabete peggiora




COLR NEG

↓ S3* ↑ TARGET/
DIABETES

*S3 (HDL/colesterolo buono) diminuisce e TARGET cresce
→ diabete peggiora

Fig.3 Relazione feature-target




Modelli Machine Learning (ML)

- Dopo l'EDA, selezionati ML prevalentemente lineari
- ML utilizzati: Linear Regression (baseline), Ridge Regression (regolarizzazione), Lasso Regression (feature selection), Random Forest (modello non lineare)
- Approccio: Cross-validation (5-fold) + Ottimizzazione degli iperparametri (se necessario)
- Valutazione con: MSE, MAE e R^2

OBIETTIVO:

Trovare il miglior ML per predire progressione diabete a un anno di distanza



Risultati

- Linear, Ridge e Lasso mostrano performance molto simili: $MSE \approx 3008$ – 3015 , $MAE \approx 44.3$ – 44.4 e $R^2 \approx 0.48$ (Fig.1-3)
- Random Forest presenta performance inferiori: $MSE \approx 3271$, $MAE \approx 46.5$ e $R^2 \approx 0.44$ (Fig.1-3)

RISULTATI:

- Modelli semplici generalizzano meglio
- Relazioni nel dataset prevalentemente lineari



Risultati

Fig.1 MSE




Fig.2 MAE






Fig.3 R₂



Risultati

- È stato scelto il modello più semplice e lineare (Linear Regression) per la predizione dei dati
- Predizioni vs valori reali: il modello segue correttamente il trend generale anche se presenti differenze tra valori reali e predetti (Fig.1)
- Feature più importanti: s1 (colesterolo totale), s5 (trigliceridi), bmi (indice di massa corporea) (Fig.2)

RISULTATI:

- Il modello cattura alcune variabili clinicamente rilevanti e precedentemente rivelate da EDA (s5, bmi)
 - Scarto tra predetto e reale quindi variabilità non completamente spiegata



Risultati

TARGET $\neq$ PREDICTED

Predictions for the first 5 rows of the dataset:

	Actual Target	Predicted Target
0	151.0	206.116677
1	75.0	68.071033
2	141.0	176.882790
3	206.0	166.914458
4	135.0	128.462258

Fig.1 Data prediction






Fig.2 Feature importance

Conclusioni

- È possibile predire la progressione del diabete utilizzando info cliniche dei pazienti
- I modelli lineari hanno mostrato buone performance anche se solo metà variabilità spiegata ($R^2 \approx 0.48$)
- Alcuni fattori non vengono catturati dal modello indicando possibili relazioni non lineari o variabili mancanti



- Il Machine Learning può rappresentare un valido supporto per l'analisi clinica
- Servono però dati più completi/modelli più avanzati per previsioni migliori



A decorative border surrounds the central text, featuring various medical and health-related icons. At the top, there are syringes, pill bottles, and a blue ribbon. On the left and right sides, there are red blood cells, a blue pill bottle, and a blue pill. At the bottom, there are two blue digital blood pressure monitors showing readings of 120 mmHg and 051 mmHg, and two blue foot scales with analog dials.

Grazie!